

자율 주행 도메인의 3D 시맨틱 세그멘테이션 을 위한 센서 퓨전 기반의 Trans-Unet

발표자 : 이윤선

INDEX

1. Introduction

2. Related Work

3. Proposed method

4. Experiment result

5. Conclusion

1. INTRODUCTION

1. Introduction

Motivation

- 카메라 기반 객체 인식 기술을 활용하는 자율주행 차량의 빈번한 사고

Goal

- 센서 퓨전 활용한 시맨틱 세그멘테이션
- 추론 결과(2D)를 실주행 환경과 같은 3D로 변환

Contribution

- 기존 2차원 시맨틱 세그멘테이션 및 센서 퓨전 접목을 통해 실주행 환경과 같은 3D로 해석

2. RELATED WORK

2. Related work


센서 퓨전

- 다수의 센서로부터 획득한 데이터를 융합하여 차량 주변의 환경 정보를 정확하게 파악하는 기술
- 각 센서간 장단점 상호 보완



Camera

카메라	센서	라이다
+	객체 인식	-
-	거리 인식	+
-	조도 차	+




Lidar


2. Related work

시맨틱 세그멘테이션

- 입력 데이터의 구성 단위마다 객체의 종류를 인식 및 분류하는 기술
- 2D 이미지: 픽셀 , 3D 포인트 클라우드: (좌표)점




2D semantic
segmentation



3D semantic
segmentation

3. PROPOSED METHOD

3. Proposed method: - model architecture



3. Proposed method:


- encoder

- ResNet

- 지역 특이점 추출

- Transformer 모듈

- 주요 특징 중시하여 심층 특징 임베딩 생성



3. Proposed method: - decoder

접합

- 컨볼루션 과정을 통해 추출한 특징 벡터 반영
 - 특징 벡터의 지역적, 구조적 복원

3x3 컨볼루션 (ReLU activation)


- 접합 과정에서 생성된 특징 맵 혼합

업샘플링

- 면적 2배 확장

1x1 컨볼루션 (Softmax activation)


- 원본 사이즈의 추론 맵 생성
- 세그멘테이션 헤드



3. Proposed method:

- 추론 결과(2D)의 역사영(3D)

- ① 전처리 과정: 3D, 2D좌표 준비
 - a. 신경망을 통한 추론 맵 생성
- ② 추론 맵의 각 좌표당 3x3 커널
 - a. Max pooling 연산
 - b. 각 좌표에 대한 세그먼트 추정
- ③ 3D 데이터의 추론 결과 획득



4. EXPERIMENT RESULT

4. Experiment Result: - implementation details

- CPU : AMD EPYC 7742 64-Core Processor
- GPU : A100 80GB
- HDD : 2TB
- ubuntu 20.04
- python 3.9
- Tensorflow 2.8.0
- Keras 2.8.0

- Dataset : Semantic KITTI(라이다) + KITTI(카메라)
 - 0 ~10 : train / valid split
 - 8 : test
- 평가 방법
 - $MIOU = \frac{1}{N} * \sum_1^N(IoU), IoU = \frac{TP}{TP+FN+FP}$

4. Experiment Result: ablation test - sensor fusion

- single modal:
 - 카메라만 활용
- multi-modal:
 - early fusion – 신경망 입력 이전 융합
 - mid fusion – 신경망 내부 융합
 - late fusion – 신경망 추론 결과 융합

Modality for Encoder	Fusion method		2D MIOU
Single modal(Camera)	-		0.1012
Multi-modal(Camera + Lidar)	early fusion		0.2045
	mid fusion	After conv 1 block	0.2113
		After conv 2 block	0.2152
		After conv 3 block	0.2021
	late fusion		0.1844

4. Experiment Result: ablation test

- Loss function

- Focal loss
 - 오분류되는 케이스에 대하여 더 큰 가중치를 주는 방법
 - $L_{focal} = -(1 - p_t)^{\gamma} \log(p_t)$
- Dice loss
 - 추론 값과 정답 사이의 유사도를 계산하여 가중치를 주는 방법
 - $L_{dice} = \frac{2 * \sum p_{true} * p_{pred}}{\sum p_{true}^2 + \sum p_{pred}^2 + \epsilon}$

Loss function	2D MIoU
Dice loss	0.2739
Focal loss	0.2240
Dice regularized Dice loss	0.2749
Dice regularized Focal loss	0.3194
Focal regularized Dice loss	0.3075

4. Experiment Result

제안 방법 성능 : 17.12%

- 추론 결과(2D) → 3D 정보 해석


3D_Coordinate	y_true	y_predict
[29.031542 14.962611 -1.8181214]	16	16
[31.030882 1.5147057 -1.7191248]	18	18
[30.303232 -6.6577306 -1.9296318]	18	18
[28.322702 -12.640519 -1.9262444]	18	18
[30.957737 1.5599654 -1.7151273]	18	18
[30.84161 -2.9298124 -1.9285618]	18	18
[29.06118 -7.9899063 -1.8681674]	18	18
[28.605034 -9.491795 -1.8675996]	18	18
[27.137468 -10.169985 -1.2472509]	16	16
[26.4572 -9.777 -1.8723754]	18	18

Network Config.	2D MIoU	3D MIoU
Single modal(Camera)	0.1012	Not Possible
Proposed method	0.3194	0.1712

4. Experiment Result

- 고찰

- 데이터 측면
 - 점군 사영 데이터의 희소성 문제
- 설계 측면
 - 신경망(Trans-Unet)을 구성하는 모듈의 단순함
- 학습 프로세스 측면
 - 신경망의 사전 학습 과정 부재



점군 사영 데이터

5. CONCLUSION

5. Conclusion

- 기존 2D 시맨틱 세그멘테이션 기법(Trans-Unet)에 멀티 모달을 수용하여 센서 퓨전 활용
- 다양한 절제 실험을 통하여 최적의 센서 퓨전, 신경망의 상세 구조 및 손실 함수 등 객관적 과정 제시
- 신경망의 추론 결과인 2D를 3D로 좌표 변환하여 실제 주행 환경에 적합한 추론 결과 획득

향후 연구

- 데이터 희소성 해결
- 효과적인 구조 및 모듈을 재구성
- 사전 학습 과정 구성

감사합니다.